Projet SILLDA : Reconnaissance labiale

Floriant RIOTTE – Théo BEN SADOUN – Maël GOAREGUER – Enzo MAGGIO – Léa POTIN

Introduction :

Contexte:
Dans le cadre d'un projet technologique, notre équipe a été sollicitée pour concevoir une application innovante de retranscription labiale en temps réel. Ce projet répond à un besoin sociétal fort : améliorer l'accessibilité à la communication pour les personnes malentendantes. La solution vise à être déployée dans divers contextes tels que les conférences, les échanges interpersonnels ou encore les supports multimédias.

Objectif:
L'objectif principal est de développer une interface capable de retranscrire la parole en temps réel en combinant plusieurs sources d'information grâce à l'IA : les mouvements des lèvres (via un script de liptracking), l'audio (via un modèle de transcription vocale) et la vidéo (via un modèle de lecture labiale). Ce projet repose sur l'intégration cohérente de ces modules avec une interface graphique intuitive. Il s'inscrit dans une démarche exploratoire mêlant intelligence artificielle, traitement du signal et interaction homme-machine.

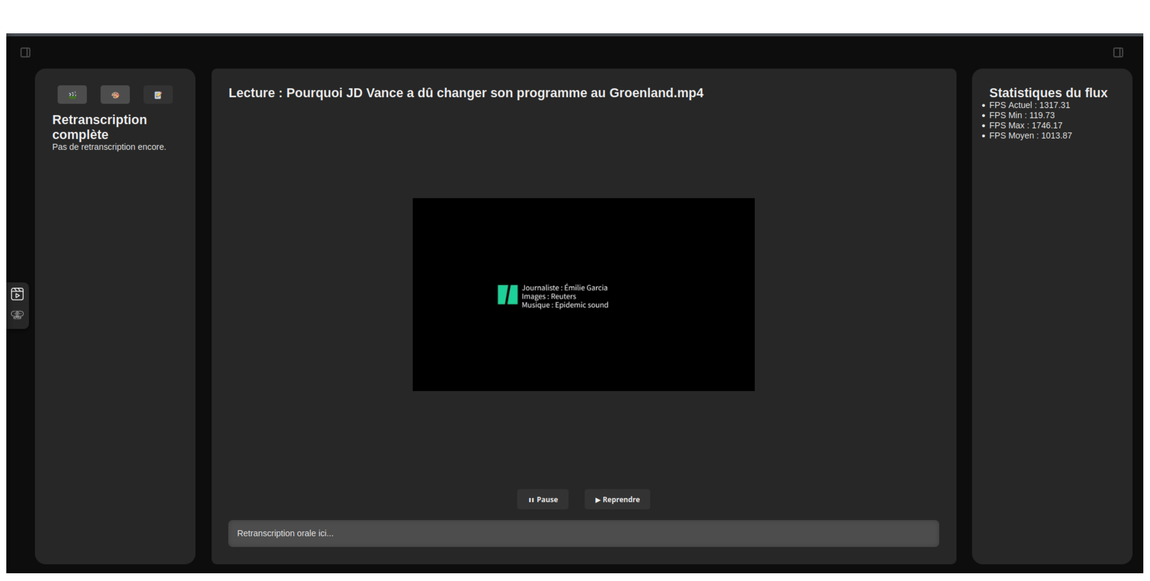


Figure 1 – Interface web de retranscription

Technologies utilisées :

TensorFlow
Bibliothèque open-source développée par Google, utilisée pour l'entraînement et l'exécution de modèles d'intelligence artificielle, notamment en traitement de données audio et visuelles.

RealTimeSTT & Whisper
Outils de reconnaissance vocale automatique permettant la transcription en temps réel de la parole, facilitant l'interaction homme-machine.

Lipreading & Liptracking
Deux dépôts Git intégrant des modèles de lecture labiale automatique et de suivi des mouvements des lèvres à partir de vidéos.

Jira & GitHub
Plateformes de gestion de projet et de versioning utilisées pour la coordination de l'équipe, le suivi des tâches et le contrôle du code source.

Ressources :

RealTimeSTT : https://github.com/KoljaB/RealtimeSTT
Lipreading : https://github.com/skaty5678/lipread_tensorflow
Liptracking : https://github.com/astorfi/lip-reading-deeplearning/tree/master?tab=readme-ov-file#lip-tracking

Grandes étapes du projet :

1 – Reconnaissance labiale
L'un des principaux défis techniques de ce projet réside dans l'intégration en temps réel de deux modèles d'intelligence artificielle complémentaires. Le premier, un modèle de suivi des lèvres, capte en direct les mouvements buccaux via une webcam. Il localise précisément la position des lèvres image par image. Le second, un modèle de retranscription labiale, exploite ces données visuelles pour interpréter les mouvements et en déduire les mots correspondants, sans support audio. Cette étape nécessite une synchronisation fluide entre les deux modèles, ainsi qu'une capacité de traitement rapide et précise, afin d'assurer une retranscription fidèle et instantanée.

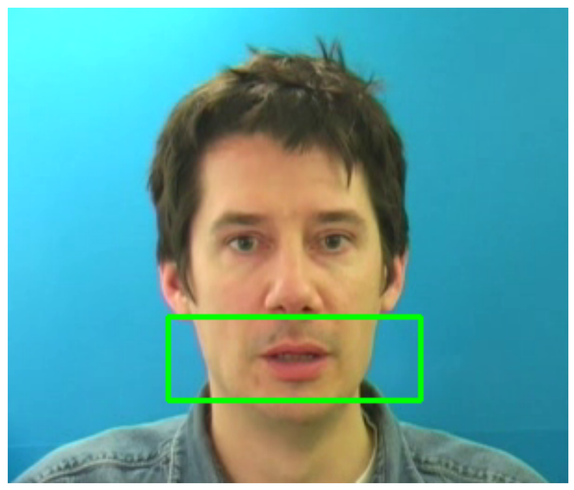


Figure 2 – Découpage du liptracking

2 – Reconnaissance audio
Pour cette partie, nous avons exploré plusieurs solutions de transcription vocale en temps réel, notamment RealTimeSTT, Whisper AI Turbo et Whisper AI. C'est finalement Whisper AI qui s'est révélée la plus performante, avec une bonne réactivité et une précision élevée.
Le système capte la voix via un microphone et la convertit automatiquement en texte, permettant ainsi une transcription instantanée des propos. Elle constitue ainsi un soutien essentiel au système global, notamment lorsque la lecture labiale atteint ses limites. Elle joue donc un rôle clé dans la robustesse de l'application, notamment en environnement réel.

Bilan et perspectives :

Bilan :
- Le projet a permis de valider l'intégration de plusieurs modules d'intelligence artificielle dans une même application. Si la retranscription audio en temps réel est plutôt fluide et précise, la composante labiale reste plus complexe à stabiliser, bien qu'elle soit satisfaisante sur des vidéos préenregistrées, l'utilisation en temps réel soulève encore des défis.

Perspectives :
- L'objectif est désormais d'améliorer la synchronisation et la réactivité des modèles en temps réel, afin d'obtenir une expérience plus fluide et utilisable en situation réelle.
- L'objectif à moyen terme est de proposer une solution robuste et accessible, capable d'aider les personnes malentendantes dans des échanges spontanés, avec une qualité proche de celle obtenue sur vidéo.

Remerciements:
Jesus FRANCO ROBLES
Enseignant référent – *Client – 3iL Ingénieurs*

Projet I2
2024 - 2025